



Introducción al Análisis de Datos

Trabajo Práctico Integrador

**Evolución de la actividad, el empleo y los ingresos en los aglomerados
Gran Córdoba y Partidos del GBA (2017-2025)**

Fuente de datos: Encuesta Permanente de Hogares (EPH) - INDEC
Docente a cargo: Fernández, Luis N.
Fecha de entrega: 22/06/2026

Introducción

Este informe presenta un análisis de la evolución de los principales indicadores del mercado de trabajo argentino entre 2017 y 2025, utilizando microdatos de la Encuesta Permanente de Hogares (EPH) que elabora el Instituto Nacional de Estadística y Censos (INDEC). El análisis se centra específicamente en la comparación entre dos aglomerados urbanos: Gran Córdoba (código 13) y los Partidos del Gran Buenos Aires (código 33).

A lo largo del trabajo se estudian la tasa de actividad, la tasa de empleo y la tasa de desocupación, así como la evolución de los ingresos de la población ocupada. Dado que el período analizado incluye años de alta inflación, los ingresos fueron ajustados mediante un proceso de deflación que los expresa en pesos constantes del cuarto trimestre de 2025, lo que permite comparaciones válidas entre puntos distantes en el tiempo.

El informe se organiza en cuatro secciones principales: en primer lugar, un análisis univariado que explora la composición de la base de microdatos, identifica valores atípicos y casos de no respuesta; en segundo lugar, un análisis multivariado que estudia la evolución histórica de los indicadores cruzados con variables como nivel educativo, sexo, edad y características del empleo; en tercer lugar, la visualización gráfica de los resultados obtenidos; y finalmente, el desarrollo de un modelo predictivo basado en ensambles de árboles de decisión (Random Forest) para la imputación de los casos de no respuesta en la variable de ingresos.

Metodología y fuente de datos

La base de datos utilizada corresponde a la base de Personas de la EPH, en su modalidad continua, para los 36 trimestres comprendidos entre 2017 y 2025. Se trabajó exclusivamente con los casos correspondientes a los aglomerados 13 (Gran Córdoba) y 33 (Partidos del GBA).

Proceso de actualización de la P21

Debido al efecto de la inflación, los valores monetarios de cada trimestre no son directamente comparables, por lo que fue necesario expresarlos en valores equivalentes a precios del período más reciente. Este procedimiento consistió en llevar todos los valores históricos del P21 al cuarto trimestre de 2025.

Primero calculamos la inflación acumulada, este cálculo se llevó a cabo sumando la inflación acumulada por mes durante 3 meses, obteniendo así la inflación acumulada de cada trimestre. Esta información se recopiló del archivo sh_ipc_06_26.xls. Los resultados fueron los siguientes:

T/AÑO	2017	2018	2019	2020	2021	2022	2023	2024	2025
1	6.1%	6.5%	11.4%	7.6%	12.4%	15.3%	20.3%	44.8%	8.3%
2	5.3%	8.5%	9.2%	5.2%	10.6%	16.4%	22.2%	17.6%	5.9%
3	5%	13.5%	12.1%	7.4%	9%	20.6%	31.4%	11.7%	5.9%
4	6%	11.2%	11.3%	11%	9.8%	16.3%	46.6%	7.8%	7.6%

El factor de actualización para cada período se calculó mediante la multiplicación acumulada de las variaciones inflacionarias posteriores al trimestre de origen hasta el período base. Por ejemplo, para actualizar un ingreso correspondiente al primer trimestre de 2017, se multiplicaron sucesivamente todos los factores inflacionarios desde el segundo trimestre del 2017 hasta el cuarto trimestre del 2025. Se realizó el siguiente cálculo:

$\text{Factor} = (1+0.053) \times (1+0.050) \times (1+0.060) \times \dots \times (1+0.076) = 74,40$ aproximadamente
 $\text{Factor} = 74,40$ aprox
 $P21 = \$18.500$
 $P21 \times \text{Factor} = P21\text{Actualizado}$
 $\$18.500 \times 74,40 = \$1.376.402,20$

Esto significa que un ingreso de \$18.500 registrado en el primer trimestre de 2017 tendría un poder adquisitivo equivalente aproximadamente a \$1.376.402,20 en el cuarto trimestre de 2025. Una vez obtenidos estos resultados creamos una nueva tabla en cada uno de los trimestres denominada “P21Actualizado” con los nuevos valores correspondientes.

Ponderación

Según las técnicas del diseño de la EPH, las tasas de actividad, empleo y desocupación fueron calculadas utilizando el ponderador PONDERA, mientras que las medidas de tendencia central y posición de los ingresos se calcularon utilizando el ponderador PONDIIIO, específico para el ingreso de la ocupación principal. Esto permite que los resultados sean representativos de la población total y no solamente de la muestra encuestada.

Análisis univariado y exploración de datos

Se realizó una exploración general de la base con el objetivo de conocer su composición, detectar problemas de calidad de datos (duplicados y no respuesta) y caracterizar la distribución de la variable de ingresos.


No respuesta en la variable de ingresos (P21)

Se identificaron los casos en los que la persona ocupada no declaró su ingreso (código -9). Este análisis es relevante ya que constituye el punto de partida para el modelo de imputación desarrollado más adelante. Se detectaron diferencias importantes entre aglomerados: en Partidos del GBA la proporción de no respuesta alcanza el 28% de los ocupados, mientras que en Gran Córdoba es de solo el 5,3%. Esta diferencia marcada entre ambos motivó el desarrollo del modelo de imputación, dado que excluir esos casos en GBA representaría descartar más de una cuarta parte de la muestra de ocupados.

Detección de duplicados

Se verificó la existencia de registros duplicados utilizando como clave la combinación de las variables ANO4, TRIMESTRE, CODUSU, NRO_HOGAR y COMPONENTE, que identifican de manera unívoca a cada individuo encuestado en cada trimestre. No se detectaron duplicados en la base consolidada, lo que confirma la integridad de la unión de los 36 archivos trimestrales.

Detección de valores atípicos en los ingresos



La detección de valores atípicos se realizó exclusivamente sobre la población ocupada (ESTADO = 1) y excluyendo los casos sin ingreso válido ($P21 \leq 0$ o no respuesta), ya que esta es la única variable numérica continua sobre la que tiene sentido aplicar la regla del rango intercuartílico (RIC). Aplicando el criterio estándar de 1,5 veces el RIC por encima del tercer cuartil, se identificó que aproximadamente el 15% de los ingresos válidos constituyen valores atípicos.

El gráfico muestra que la mayoría de los ingresos se concentra en valores bajos, pero existe un grupo reducido de personas con ingresos muy altos que se aleja del resto. Este fenómeno es más marcado en Partidos del GBA, lo que sugiere una distribución del ingreso más desigual que en Gran Córdoba. Por esta razón, en todo el análisis se utilizó la mediana en lugar del promedio, ya que este último se distorsiona fácilmente por esos valores extremos.


Variables de empleo

Para la población ocupada se analizaron también la rama de actividad económica (PP04B_COD) y el nivel de calificación de la tarea, obtenido a partir del último dígito de PP04D_COD según el Clasificador Nacional de Ocupaciones. Las categorías de calificación identificadas son: Profesional, Técnica, Operativa y No calificada. Estas variables resultan fundamentales para el análisis multivariado desarrollado en la siguiente sección.

Análisis multivariado: evolución histórica de los indicadores

En esta sección se presenta la evolución trimestral de los indicadores del mercado de trabajo y de los ingresos, cruzados con variables sociodemográficas y de características del empleo, para el período 2017-2025.

Tasas de actividad, empleo y desocupación




El hecho más saliente de la serie es la caída abrupta registrada en el segundo trimestre de 2020, coincidente con el aislamiento social, preventivo y obligatorio decretado por la pandemia de COVID-19. En ese trimestre, la tasa de actividad de Partidos del GBA se desplomó a 42,3%, mientras que en Gran Córdoba el impacto fue algo menor, descendiendo a 51,0%. De manera consistente, la tasa de empleo de GBA cayó a 36,4% y la de Córdoba a 41,2%.

La tasa de desocupación muestra su pico histórico en el mismo período crítico, alcanzando 19,1% en Gran Córdoba en el segundo trimestre del 2020. Es interesante notar que, en términos de empleo y actividad, GBA fue el aglomerado más afectado por la pandemia, mientras que en términos de desocupación Córdoba mostró mayor deterioro, lo que se explica por una recuperación más rápida del lado de la oferta laboral en Córdoba.

Tras la recuperación post pandemia, ambos aglomerados tienden a estabilizarse en valores de participación laboral y ocupación que superan las cifras observadas al comienzo del estudio.

Hacia el cuarto trimestre del 2025, Gran Córdoba exhibe una tasa de actividad de 58,3% y una tasa de empleo de 53,1%, levemente superiores a las de Partidos del GBA que cuenta con 55,7% y 50,4%. La tasa de desocupación se ubica en niveles similares en ambos aglomerados hacia el final de la serie, en torno al 9%, sensiblemente por debajo de los picos registrados durante 2020 y 2021.


Evolución de los ingresos reales



La mediana de ingresos reales partió de un valor similar en ambos aglomerados en el primer trimestre del 2017, y atravesó un descenso hasta alcanzar un mínimo histórico en el primer trimestre del 2024, con \$462.649 en ambos aglomerados. Este deterioro sostenido del poder adquisitivo coincide con el período de mayor aceleración inflacionaria de la serie (2023-2024), donde la inflación trimestral llegó a superar el 46%.


A partir del segundo trimestre del 2024 se observa una recuperación marcada y sostenida del ingreso real, que se acelera especialmente durante 2025. Hacia el cierre del cuarto trimestre del 2025, la mediana de ingresos alcanza \$840.000 en Gran Córdoba y \$800.000 en Partidos del GBA, superando los valores iniciales de 2017 y constituyendo el nivel más alto de toda la serie histórica analizada.

Dispersión de los ingresos: mediana, primer y tercer cuartil




El análisis de la dispersión del ingreso a través de los cuartiles muestra que la brecha entre Q1 y Q3 se mantiene relativamente estable a lo largo del tiempo, aunque se amplía durante el período de recuperación posterior a 2024, lo que indica que el aumento de ingresos no fue completamente homogéneo entre los distintos niveles de la distribución.

Ingresos por sexo




Se observa una brecha de ingresos por género persistente y sostenida a lo largo de toda la serie, en ambos aglomerados. En el cuarto trimestre del 2025, la mediana de ingresos de los varones ocupados (\$900.000 en Córdoba y \$1.000.000 en GBA) supera en aproximadamente 28% y 67% respectivamente a la de las mujeres (\$700.000 en Córdoba y \$600.000 en GBA). Esta brecha es más pronunciada en Partidos del GBA que en Gran Córdoba en el último período observado, aunque ambas series muestran una tendencia de ampliación de la brecha hacia el final de la serie, en el marco de la recuperación general de los ingresos reales.


Ingresos por nivel educativo



Se confirma el patrón esperado según la literatura económica: a mayor nivel educativo, mayor ingreso mediano. La categoría Superior completo se ubica sistemáticamente por encima del resto en ambos aglomerados, mientras que Primario incompleto y Primario completo se ubican en el extremo inferior. La categoría Sin instrucción presenta alta volatilidad trimestre a trimestre, lo cual resulta esperable dado el reducido tamaño muestral de este grupo dentro de la población ocupada.



Ingresos por rango etario






Los datos muestran el clásico perfil de ingresos por ciclo de vida laboral: el grupo de 14 a 25 años percibe sistemáticamente los ingresos más bajos, mientras que los grupos de edades intermedias (36 a 55 años) alcanzan los niveles más altos, en coincidencia con los años de mayor experiencia y consolidación profesional. El grupo de 66 años y más muestra alta variabilidad, asociada a un menor número de casos y a la heterogeneidad de las personas que continúan en actividad luego de la edad jubilatoria.

Ingresos por nivel de calificación de la ocupación



La jerarquía de ingresos según calificación se mantiene estable a lo largo de toda la serie: las ocupaciones de calificación Profesional perciben sistemáticamente los ingresos más altos, seguidas por las Técnicas, las Operativas y, en último lugar, las No calificadas. Hacia el cuarto trimestre del 2025, la mediana de ingresos de una ocupación profesional (\$1.100.000 en Córdoba, \$1.400.000 en GBA) más que duplica a la de una ocupación no calificada (\$480.000 y \$500.000 respectivamente), lo que evidencia una brecha estructural muy marcada asociada a la calificación de la tarea desempeñada.

Ingresos por rama de actividad económica



Dado que la clasificación de ramas de actividad cuenta con un elevado número de categorías, se seleccionaron para cada aglomerado las cinco ramas con mayor ingreso mediano promedio en la serie, con el objetivo de favorecer la legibilidad del gráfico. En ambos aglomerados, Administración pública y Construcción se ubican entre las ramas de mayores ingresos. En Gran Córdoba se destaca además el sector de Educación y salud, mientras que en Partidos del GBA cobra mayor relevancia el sector de Electricidad, gas y agua. Cabe señalar que tanto esta rama como la categoría "Sin instrucción" del nivel educativo presentan un número reducido de casos muestrales por trimestre, lo que se traduce en una alta volatilidad de sus medianas trimestrales y exige cautela al interpretar esas series específicas.

Modelo de imputación de la no respuesta en ingresos

Para imputar los 28.222 casos de no respuesta en la variable de ingresos ($P21 = -9$), se desarrolló un modelo de ensamble basado en Random Forest, compuesto por 100 árboles de decisión con profundidad máxima de 10 niveles y un mínimo de 50 observaciones por hoja. Este tipo de modelo fue elegido por su mayor capacidad para capturar relaciones no lineales entre las variables respecto de la regresión lineal, con el objetivo de mejorar el poder predictivo.

Las variables independientes utilizadas fueron sexo (CH04), edad (CH06), nivel educativo (NIVEL_ED) y nivel de calificación de la ocupación (último dígito de PP04D_COD). Las variables categóricas fueron transformadas mediante codificación dummy. El conjunto de datos se dividió en 80% para entrenamiento y 20% para validación, y tanto el entrenamiento como las métricas de evaluación fueron calculadas ponderando por PONDIO, de manera consistente con el criterio utilizado en el resto del informe.

Evaluación del rendimiento del modelo

Métrica	Valor	Interpretación
R ² ponderado	0,2519	El modelo explica el 25,2% de la variabilidad del ingreso real
MAE ponderado	\$385.983	Error promedio absoluto de la predicción, en pesos constantes de 2025

El R² obtenido (0,2519) mejora el resultado de la regresión lineal múltiple ensayada previamente (0,2260), lo que confirma que el Random Forest logra capturar mejor las relaciones entre las variables. Sin embargo, el poder explicativo sigue siendo moderado, lo cual es esperable en modelos de ingresos basados en encuestas de hogares, donde el ingreso depende de muchos factores no observables como la antigüedad, el tamaño de la empresa o las condiciones del convenio colectivo. En la misma línea, si bien el Random Forest logró reducir el error medio absoluto a \$385.983 frente a los \$394.847 de la regresión lineal, este valor continúa siendo elevado en relación con la mediana de ingresos de la serie. Por ello, los valores imputados deben interpretarse como una aproximación razonable a nivel agregado, y no como una estimación precisa a nivel individual.

Interpretación de las variables independientes

Variable	Importancia (%)	Interpretación
CH04 2 (Mujer)	19,3%	El sexo tiene un peso similar a la edad en la predicción
CH06 (Edad)	19,6%	La edad constituye una de las variables más importantes del modelo.
calif_2 (Técnica)	6,8%	La calificación ocupacional contribuye significativamente a la capacidad predictiva del modelo
calif_3 (Operativa)	8,2%	La calificación ocupacional aporta información relevante para diferenciar niveles de ingreso
calif_4 (No calificada)	6,2%	La condición de ocupación no calificada participa en la segmentación de ingresos realizada por el modelo
NIVEL_ED_5 (Superior incompleto)	4,3%	Aporte relevante aún sin completar el nivel superior
NIVEL_ED_4 (Secundario completo)	4,0%	Niveles educativos intermedios con aporte menor
NIVEL_ED_3 (Secundario incompleto)	1,1%	Aporte marginal
NIVEL_ED_6 (Superior completo)	29,7%	La variable más influyente en la predicción del ingreso

Las variables NIVEL_ED_2, NIVEL_ED_7 y las categorías residuales calif_7, calif_8 y calif_9 presentaron importancias inferiores al 1% y se omitieron de la tabla para facilitar la lectura.

A diferencia de la regresión lineal donde se analizan coeficientes, en Random Forest la importancia de cada variable indica cuánto contribuye en promedio a reducir el error de predicción en todos los árboles del ensamble. Los resultados son coherentes con el análisis descriptivo: el nivel educativo (especialmente Superior completo con 29,7%) y la edad (19,6%) son los predictores más fuertes, seguidos por el sexo (19,3%), lo que indica que esta variable posee una relevancia importante para la predicción de ingresos dentro del modelo. .

Imputación final

Aplicando el modelo sobre los 28.222 casos de no respuesta, se generaron predicciones de ingreso para cada uno, acotadas a valores no negativos. Estos valores reemplazan los códigos -9 en la columna P21 actualizado, generando una base de datos completa sin valores faltantes en la variable de ingresos, disponible para análisis posteriores que requieran trabajar sin exclusión de casos.

Conclusiones

El análisis del mercado de trabajo de Gran Córdoba y Partidos del GBA entre 2017 y 2025 permite identificar varios patrones consistentes:

- La pandemia de COVID-19 constituyó el evento de mayor impacto sobre los indicadores laborales de toda la serie, con caídas históricas en las tasas de actividad y empleo, y un pico de desocupación, particularmente pronunciado en Gran Córdoba.
- El poder adquisitivo de los ingresos laborales atravesó un fuerte deterioro entre 2017 y 2024, en sintonía con el proceso inflacionario, alcanzando su punto más bajo en el primer trimestre del 2024, para luego recuperarse sostenidamente en 2024 y 2025 hasta superar los niveles iniciales de la serie.
- Persiste una brecha de ingresos por género en ambos aglomerados, que se manifiesta de forma más marcada en Partidos del GBA que en Gran Córdoba.
- El nivel educativo y la calificación de la ocupación son los factores que muestran la asociación más clara y estable con el nivel de ingresos a lo largo de toda la serie, confirmando la relevancia del capital humano como determinante del ingreso laboral.
- Ambos aglomerados muestran trayectorias similares en sus indicadores, aunque Gran Córdoba muestra tasas de actividad y empleo levemente superiores a las de Partidos del GBA hacia el final del período analizado.
- El modelo de Random Forest desarrollado para imputar la no respuesta en ingresos confirma los principales hallazgos descriptivos del informe: el nivel educativo (29,7% de importancia) y la edad (19,6%) son los predictores más fuertes, y el sexo (19,3% de importancia) constituye una de las variables más relevantes para la predicción de ingresos. El poder explicativo del modelo es moderado ($R^2 = 0,2519$), lo que indica que buena parte de la variabilidad del ingreso responde a factores no captados por las variables disponibles en la encuesta.